eda_car_insurance_claim.ipynb

Arquivo Editar Ver Inserir Ambiente de execução Ferramentas Ajuda

Comandos + Código + Texto Executar tudo

Compartilhar

Arquivos

- sample_data
- Car_Insurance_Claim.csv
- car_insurance_claim_tratado.csv

Teste Técnico - Analista de Dados

Dataset: Car Insurance Claim

Objetivo

Analisar a taxa de sinistro (`OUTCOME`) por segmentos e identificar fatores associados a maior risco, gerando insights para apoiar decisões de precificação, underwriting e retenção.

O foco da análise será:

- Entender o comportamento da variável alvo (`OUTCOME`)
- Identificar padrões de risco por perfil de cliente
- Gerar recomendações práticas de negócio

2. Leitura da base

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

pd.set_option('display.max_columns', None)
sns.set_style("whitegrid")

df = pd.read_csv('/content/Car_Insurance_Claim.csv')

df.head()
```

	ID	AGE	GENDER	RACE	DRIVING_EXPERIENCE	EDUCATION	INCOME	CREDIT_SCORE	VEHICLE_OWNERSHIP	VEHICLE_YEAR	MARRIED	CHILDREN	POSTAL_CODE	ANNUAL_MILEAGE	VEHICLE_TYPE	SPEEDING_VIOLATIONS	DUIS	PAST_ACCIDENTS	OUTCOME
0	569520	65+	female	majority	0-9y	high school	upper class	0.629027	1.0	after 2015	0.0	1.0	10238	12000.0	sedan	0	0	0	0.0
1	750365	16-25	male	majority	0-9y	none	poverty	0.357757	0.0	before 2015	0.0	0.0	10238	16000.0	sedan	0	0	0	1.0
2	199901	16-25	female	majority	0-9y	high school	working class	0.493146	1.0	before 2015	0.0	0.0	10238	11000.0	sedan	0	0	0	0.0
3	478866	16-25	male	majority	0-9y	university	working class	0.206013	1.0	before 2015	0.0	1.0	32765	11000.0	sedan	0	0	0	0.0
4	731664	26-39	male	majority	10-19y	none	working class	0.388366	1.0	before 2015	0.0	0.0	32765	12000.0	sedan	2	0	1	1.0

Próximas etapas: Gerar código com df | New interactive sheet

eda_car_insurance_claim.ipynb

Arquivo Editar Ver Inserir Ambiente de execução Ferramentas Ajuda

Comandos + Código + Texto Executar tudo

Compartilhar

Arquivos

- sample_data
- Car_Insurance_Claim.csv
- car_insurance_claim_tratado.csv

Disco Disponível: 86.38 GB

3. Visão geral e auditoria

```
print("Linhas:", df.shape[0])
print("Colunas:", df.shape[1])
```

```
Linhas: 10000
Colunas: 19
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 19 columns):
 #   Column                 Non-Null Count  Dtype
---  ------                 --------------  -----
 0   ID                     10000 non-null  int64
 1   AGE                    10000 non-null  object
 2   GENDER                 10000 non-null  object
 3   RACE                   10000 non-null  object
 4   DRIVING_EXPERIENCE     10000 non-null  object
 5   EDUCATION              10000 non-null  object
 6   INCOME                 10000 non-null  object
 7   CREDIT_SCORE           9018 non-null   float64
 8   VEHICLE_OWNERSHIP      10000 non-null  float64
 9   VEHICLE_YEAR           10000 non-null  object
 10  MARRIED                10000 non-null  float64
 11  CHILDREN               10000 non-null  float64
 12  POSTAL_CODE            10000 non-null  int64
 13  ANNUAL_MILEAGE         9043 non-null   float64
 14  VEHICLE_TYPE           10000 non-null  object
 15  SPEEDING_VIOLATIONS    10000 non-null  int64
 16  DUIS                   10000 non-null  int64
 17  PAST_ACCIDENTS         10000 non-null  int64
 18  OUTCOME                10000 non-null  float64
dtypes: float64(6), int64(5), object(8)
memory usage: 1.4+ MB
```

```
df.isnull().sum().sort_values(ascending=False)
```

	0
CREDIT_SCORE	982
ANNUAL_MILEAGE	957
ID	0
GENDER	0
AGE	0
EDUCATION	0
RACE	0
INCOME	0
VEHICLE_OWNERSHIP	0
VEHICLE_YEAR	0

Arquivo Editar Ver Inserir Ambiente de execução Ferramentas Ajuda

Comandos + Código + Texto Executar tudo

Arquivos

- sample_data
- Car_Insurance_Claim.csv
- car_insurance_claim_tratado.csv

```
df.duplicated().sum()
```

```
np.int64(0)
```

```
df['OUTCOME'].value_counts(normalize=True)
```

OUTCOME	proportion
0.0	0.6867
1.0	0.3133

dtype: float64

```
sns.countplot(data=df, x='OUTCOME')
plt.title('Distribuição de OUTCOME')
plt.show()
```

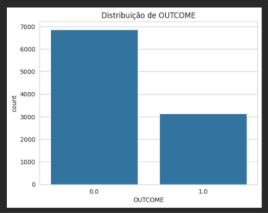

Auditoria inicial

O dataset possui 10.000 registros e 19 colunas, contendo informações demográficas, perfil financeiro, histórico de direção e características do veículo.

Foram identificados valores ausentes principalmente nas variáveis `CREDIT_SCORE` e `ANNUAL_MILEAGE` .

Não foram encontrados registros duplicados.

A variável alvo (`OUTCOME`) apresenta distribuição desbalanceada moderada, com maior concentração de clientes sem sinistro, porém com volume suficiente de eventos para análise.

eda_car_insurance_claim.ipynb

Arquivo Editar Ver Inserir Ambiente de execução Ferramentas Ajuda

Comandos + Código + Texto Executar tudo

Compartilhar

Arquivos

- sample_data
- Car_insurance_Claim.csv
- car_insurance_claim_tratado.csv

Disco Disponível: 86.38 GB

4. Tratamento dos dados

```
df_tratado = df.copy()

df_tratado['CREDIT_SCORE'] = df_tratado['CREDIT_SCORE'].fillna(df_tratado['CREDIT_SCORE'].median())
df_tratado['ANNUAL_MILEAGE'] = df_tratado['ANNUAL_MILEAGE'].fillna(df_tratado['ANNUAL_MILEAGE'].median())
```

Estratégia de tratamento

Os valores ausentes nas variáveis `CREDIT_SCORE` e `ANNUAL_MILEAGE` foram preenchidos utilizando a mediana.

A escolha da mediana se deve ao fato dessas variáveis apresentarem possíveis distribuições assimétricas e presença de valores extremos, tornando a média menos robusta.

Essa abordagem permite preservar o volume de dados sem introduzir distorções relevantes na distribuição.

5. KPIs principais

```
total_clientes = len(df_tratado)
total_sinistros = int(df_tratado['OUTCOME'].sum())
taxa_sinistro = df_tratado['OUTCOME'].mean()

print("Total de clientes:", total_clientes)
print("Total de sinistros:", total_sinistros)
print("Taxa de sinistro:", round(taxa_sinistro * 100, 2), "%")
```

```
Total de clientes: 10000
Total de sinistros: 3333
Taxa de sinistro: 33.33 %
```

6. Análise por segmento

```
def taxa_por_categoria(df, coluna):
    tabela = df.groupby(coluna, observed=False).agg(
        clientes=('OUTCOME', 'count'),
        sinistros=('OUTCOME', 'sum'),
        taxa_sinistro=('OUTCOME', 'mean')
    ).reset_index().sort_values(by='taxa_sinistro', ascending=False)

    tabela['taxa_sinistro'] = (tabela['taxa_sinistro'] * 100).round(2)
    return tabela
```

```
idade = taxa_por_categoria(df_tratado, 'AGE')
idade
```

	AGE	clientes	sinistros	taxa_sinistro
0	16-25	2016	1448.0	71.83
1	26-39	3063	1032.0	33.69
2	40-64	2931	457.0	15.59
3	65+	1990	196.0	9.85

Próximas etapas: Gerar código com idade | New interactive sheet

eda_car_insurance_claim.ipynb

Arquivo Editar Ver Inserir Ambiente de execução Ferramentas Ajuda

Comandos + Código + Texto Executar tudo

Compartilhar

Arquivos

- sample_data
- Car_insurance_Claim.csv
- car_insurance_claim_tratado.csv

Próximas etapas: Gerar código com idade | New interactive sheet

```
sns.barplot(data=idade, x='AGE', y='taxa_sinistro')
plt.title('Taxa de sinistro por idade')
plt.show()
```

```
exp = taxa_por_categoria(df_tratado, 'DRIVING_EXPERIENCE')
exp
```

	DRIVING_EXPERIENCE	clientes	sinistros	taxa_sinistro
0	0-9y	3530	2217.0	62.80
1	10-19y	3299	787.0	23.86
2	20-29y	2119	109.0	5.14
3	30y+	1052	20.0	1.90

Próximas etapas: Gerar código com exp | New interactive sheet

```
renda = taxa_por_categoria(df_tratado, 'INCOME')
renda
```

	INCOME	clientes	sinistros	taxa_sinistro
1	poverty	1814	1186.0	65.38
3	working class	1712	776.0	45.33
0	middle class	2138	592.0	27.69
2	upper class	4336	579.0	13.35

Próximas etapas: Gerar código com renda | New interactive sheet

eda_car_insurance_claim.ipynb

Arquivo Editar Ver Inserir Ambiente de execução Ferramentas Ajuda

Comandos + Código + Texto Executar tudo

Compartilhar

Arquivos

- sample_data
- Car_insurance_Claim.csv
- car_insurance_claim_tratado.csv

```
veiculo = taxa_por_categoria(df_tratado, 'VEHICLE_TYPE')
veiculo
```

	VEHICLE_TYPE	clientes	sinistros	taxa_sinistro
1	sports car	477	155.0	32.49
0	sedan	9523	2978.0	31.27

Próximas etapas: Gerar código com veiculo | New interactive sheet

Análise geral dos segmentos

Observa-se variação relevante na taxa de sinistro entre diferentes perfis de clientes.

Segmentos com menor experiência de direção e determinados perfis socioeconômicos apresentam maior incidência de sinistros, indicando possível correlação com comportamento de risco.

7. Drivers de risco

```
df_tratado['CREDIT_SCORE_FAIXA'] = pd.qcut(
    df_tratado['CREDIT_SCORE'],
    q=4,
    labels=['Baixo', 'Médio-Baixo', 'Médio-Alto', 'Alto']
)

taxa_por_categoria(df_tratado, 'CREDIT_SCORE_FAIXA')

## Disclaimer: Observa-se uma relação clara entre score de crédito e taxa de sinistro. Clientes na faixa de menor score apresentam risco substancialmente superior aos de score mais alto, sugerindo que essa variável pode ser relevante para decisões de precificação e underwriting.
```

	CREDIT_SCORE_FAIXA	clientes	sinistros	taxa_sinistro
0	Baixo	2500	1336.0	53.44
1	Médio-Baixo	2991	981.0	32.80
2	Médio-Alto	2009	435.0	21.65
3	Alto	2500	381.0	15.24

eda_car_insurance_claim.ipynb

Arquivo Editar Ver Inserir Ambiente de execução Ferramentas Ajuda

Comandos + Código + Texto Executar tudo

Compartilhar

Arquivos

- ..
- sample_data
- Car_Insurance_Claim.csv
- car_insurance_claim_tratado.csv

```python
def faixa_acidentes(x):
    if x == 0:
        return '0'
    elif x == 1:
        return '1'
    elif x <= 3:
        return '2-3'
    else:
        return '4+'

df_tratado['PAST_ACCIDENTS_FAIXA'] = df_tratado['PAST_ACCIDENTS'].apply(faixa_acidentes)

taxa_por_categoria(df_tratado, 'PAST_ACCIDENTS_FAIXA')
```

	PAST_ACCIDENTS_FAIXA	clientes	sinistros	taxa_sinistro
0	0	5584	2623.0	46.97
1	1	1783	268.0	15.03
2	2-3	1750	198.0	11.31
3	4+	883	44.0	4.98

```python
heatmap_df = pd.pivot_table(
    df_tratado,
    values='OUTCOME',
    index='DRIVING_EXPERIENCE',
    columns='PAST_ACCIDENTS_FAIXA',
    aggfunc='mean'
)

sns.heatmap(heatmap_df * 100, annot=True, fmt='.1f', cmap='Reds')
plt.title('Taxa de sinistro (%) - Experiência x Acidentes')
plt.show()
```

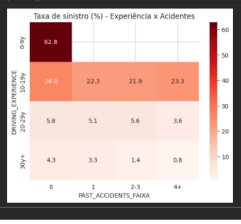

Car_Insurance_Claim.csv

car_insurance_claim_tratado.csv

Análise de drivers de risco

O histórico de acidentes e a experiência de direção se destacam como fatores relevantes para explicação do risco.

Clientes com menor experiência e maior histórico de acidentes apresentam significativamente maior probabilidade de sinistro, indicando comportamento recorrente de risco.

8. Principais insights

1. Clientes com menor experiência de direção apresentam maior taxa de sinistro.
2. O histórico de acidentes é um forte indicador de recorrência de sinistros.
3. Clientes com menor credit score apresentam maior risco.
4. Maior quilometragem anual está associada a maior exposição ao risco.
5. Infrações como multas e DUI aumentam significativamente a probabilidade de sinistro.

9. Próximos passos / recomendações

- Ajustar precificação para clientes com histórico de acidentes.
- Criar políticas de underwriting mais rigorosas para perfis de alto risco.
- Incentivar comportamentos seguros com benefícios para clientes de baixo risco.
- Monitorar clientes com alto volume de quilometragem anual.
- Utilizar modelos preditivos para antecipação de risco.

```python
df_tratado.to_csv('base_tratada.csv', index=False)
```